

LAPORAN PROYEK BIG DATA

Implementasi Big Data Pipeline Berbasis SQL dan NoSQL Menggunakan Ekosistem Apache spark untuk Analisis Faktor Risiko Diabetes Berdasarkan BMI, Hipertensi, Riwayat Merokok, dan Kadar Glukosa Darah



Disusun Oleh:

11423004 : Marselino Tambunan
11423033 : Rino Jeremia Christopher Gultom
11423035 : Elisabeth Pasaribu
11423060 : Gracia Anggraini Manik
11423066 : Stefani Margareth Rajagukguk

**PROGRAM STUDI D4 TEKNOLOGI REKAYASA
PERANGKAT LUNAK**

INSTITUT TEKNOLOGI DEL

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Diabetes mellitus merupakan salah satu penyakit kronis yang paling banyak diderita masyarakat global dan menjadi beban kesehatan yang signifikan. Menurut data International Diabetes Federation (IDF), jumlah penderita diabetes terus meningkat setiap tahunnya, menjadikan deteksi dini dan pemahaman terhadap faktor risiko diabetes sebagai prioritas kesehatan masyarakat.

Seiring berkembangnya era digital, volume data kesehatan yang dihasilkan dari berbagai sumber seperti rekam medis elektronik, sensor wearable, dan survei kesehatan populasi tumbuh secara eksponensial. Data dalam skala besar ini tidak dapat diproses secara efisien menggunakan pendekatan tradisional, sehingga diperlukan pendekatan big data yang mampu menangani volume, kecepatan, dan keberagaman data secara simultan.

Ekosistem Apache Spark, yang dikombinasikan dengan sistem penyimpanan SQL (PostgreSQL) dan NoSQL (MongoDB), menawarkan arsitektur pipeline yang andal untuk memproses dataset kesehatan berskala besar. Dataset yang digunakan dalam proyek ini adalah Diabetes Prediction Dataset yang memuat 100.000 rekam medis pasien dengan fitur klinis seperti BMI, kadar HbA1c, kadar glukosa darah, riwayat hipertensi, dan riwayat merokok.

Proyek ini mengimplementasikan pipeline big data secara end-to-end mulai dari ingesti data CSV, preprocessing, exploratory data analysis (EDA), penyimpanan ke basis data SQL dan NoSQL, hingga visualisasi interaktif berbasis Streamlit.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah proyek ini adalah:

1. Bagaimana merancang dan mengimplementasikan pipeline big data yang mampu memproses dataset diabetes berskala besar secara efisien?
2. Faktor risiko klinis apa saja (BMI, hipertensi, riwayat merokok, kadar glukosa darah) yang memiliki hubungan signifikan secara statistik terhadap kejadian diabetes?
3. Bagaimana mengintegrasikan penyimpanan SQL (PostgreSQL) dan NoSQL (MongoDB) yang saling melengkapi dalam satu arsitektur pipeline?
4. Bagaimana menyajikan hasil analisis secara interaktif melalui dashboard yang dapat digunakan oleh pengguna non-teknis?

1.3 Tujuan Proyek

Tujuan dari proyek ini adalah:

1. Membangun pipeline big data end-to-end yang mencakup tahap ingestion, processing, storage, dan visualization.
2. Mengidentifikasi dan mengidentifikasi faktor risiko diabetes berdasarkan analisis statistik terhadap variabel BMI, hipertensi, riwayat merokok, dan kadar glukosa darah.
3. Mengimplementasikan arsitektur penyimpanan hybrid SQL-NoSQL untuk

memisahkan data klinis terstruktur dan data riwayat medis semi-terstruktur.

4. Mengembangkan dashboard Streamlit interaktif sebagai antarmuka eksplorasi data bagi pengguna.

1.4 Manfaat Proyek

1.4.1 Manfaat Akademik

Proyek ini memberikan kontribusi akademik berupa implementasi nyata dari konsep big data pipeline yang meliputi komponen ingestion, processing, storage, dan visualization. Hasil proyek ini juga mendemonstrasikan integrasi teknologi SQL dan NoSQL dalam satu arsitektur.

1.4.2 Manfaat Praktis

Dari sisi praktis, pipeline DiabetaLens yang dibangun di atas dataset 100.000 rekam medis ini dapat langsung diadaptasi oleh fasilitas kesehatan untuk mendukung deteksi dini diabetes berbasis data, karena seluruh tahapan mulai dari pembersihan data via Apache Spark, penyimpanan klinis di PostgreSQL (Supabase), hingga penyimpanan data gaya hidup di MongoDB telah dikemas dalam satu alur yang modular dan terdokumentasi. Dashboard Streamlit yang dihasilkan memungkinkan tenaga kesehatan dan pengambil kebijakan mengeksplorasi pola risiko diabetes secara interaktif — mulai dari distribusi BMI, tren usia, profil merokok, hingga segmentasi pasien berdasarkan *risk score* — tanpa harus memahami satu baris kode pun. Arsitektur tiga lapis yang sudah berjalan ini juga membuka ruang pengembangan lanjutan yang realistis, misalnya penambahan model prediksi *machine learning* di atas fitur-fitur yang sudah direkayasa seperti *risk_score*, *hba1c_cat*, dan *gluc_cat*, atau integrasi koneksi database langsung ke Supabase dan MongoDB secara *live* sehingga dashboard tidak lagi bergantung pada file CSV statis melainkan mencerminkan data pasien secara *real-time*.

BAB II

TINJAUAN PUSTAKA

2.1 Karakteristik Big Data

Big data didefinisikan sebagai kumpulan data yang memiliki karakteristik yang melampaui kemampuan sistem manajemen basis data konvensional untuk ditangkap, dikelola, dan diproses dalam waktu yang dapat diterima. Karakteristik utama big data dirangkum dalam model "5V", yaitu Volume, Velocity, Variety, Veracity, dan Value.

2.1.1 Volume

Volume merujuk pada besarnya ukuran data yang dihasilkan dan dikumpulkan. Dataset yang digunakan dalam proyek ini mencakup 100.000 baris rekam medis pasien dengan sembilan atribut klinis, yang mewakili skala data yang memerlukan pendekatan pemrosesan terstruktur. Dalam konteks yang lebih besar, sistem kesehatan nyata menghasilkan data dalam skala terabyte hingga petabyte dari berbagai sumber rekam medis elektronik

2.1.2 Velocity

Velocity mengacu pada kecepatan data dihasilkan, dikumpulkan, dan diproses. Pada proyek ini, velocity diwujudkan melalui pipeline ingestion yang memuat dan memproses 100.000 rekam medis secara batch, serta penggunaan chunking (5.000 baris per batch) pada proses penulisan ke PostgreSQL dan MongoDB untuk menjaga efisiensi throughput tanpa membebani memori sistem.

2.1.3 Variety

Variety mengacu pada keberagaman tipe dan format data. Proyek ini menangani dua kategori data secara bersamaan: data klinis terstruktur yang disimpan di PostgreSQL (usia, gender, BMI, hbA1c, glukosa darah, status diabetes) dan data riwayat medis semi-terstruktur berbentuk dokumen nested yang disimpan di MongoDB (riwayat hipertensi, penyakit jantung, riwayat merokok). Pemisahan ini mencerminkan variety yang inheren dalam data kesehatan.

2.1.4 Veracity

Veracity berkaitan dengan kualitas, akurasi, dan kepercayaan data. Dataset raw memiliki beberapa masalah kualitas data yang ditangani dalam tahap preprocessing: nilai usia yang tidak valid (desimal atau di bawah 20 tahun) dikoreksi melalui randomisasi dalam rentang yang wajar, nilai BMI dan HbA1c dengan pemisah desimal yang inkonsisten (koma vs titik) distandarisasi, dan kategori smoking_history yang redundan (lima kategori) dikonsolidasikan

menjadi tiga kategori yang bermakna klinis (current, former, never).

2.1.5 Value

Value adalah dimensi paling kritis dari big data yaitu kemampuan mengekstrak nilai bisnis atau ilmiah yang bermakna dari data yang tersedia. Dalam proyek ini, value diwujudkan melalui serangkaian analisis statistik yang mengidentifikasi faktor risiko diabetes secara kuantitatif, serta dashboard interaktif yang memungkinkan pemangku kepentingan mengeksplorasi temuan tersebut secara mandiri.

2.2 Teknologi Yang Digunakan

Berikut adalah teknologi utama yang digunakan dalam proyek ini:

Teknologi	Kategori	Fungsi dalam Proyek
Python (Pandas, NumPy)	Processing	Preprocessing, EDA, dan analisis statistik
Matplotlib & Seaborn	Visualization	Pembuatan visualisasi statistik dan EDA
PostgreSQL (Supabase)	SQL Storage	Penyimpanan data klinis terstruktur
SQLAlchemy + psycopg2	ORM/Connector	Koneksi dan penulisan data ke PostgreSQL
MongoDB	NoSQL Storage	Penyimpanan dokumen riwayat medis nested
PyMongo	Driver NoSQL	Koneksi dan operasi MongoDB dari Python
Streamlit	Dashboard	Dashboard interaktif untuk eksplorasi data
SciPy (stats)	Statistical	Uji Mann-Whitney U dan Chi-Square
Jupyter Notebook	Environment	Lingkungan pengembangan dan eksperimen

BAB III

ANALISIS DAN PERANCANGAN SISTEM

3.1 Perancangan Arsitektur Sistem

3.1.1 Data Source

Dataset yang digunakan adalah Diabetes Prediction Dataset, sebuah dataset publik yang tersedia di platform [KAGGLE- Diabetes Prediction Dataset](#) yang diunggah oleh *user* dengan nama Mohammed Mustafa. Dataset berikut memiliki 100.000 data rekam medis pasien seperti usia, jenis kelamin, indeks massa tubuh (BMI), riwayat hipertensi, penyakit jantung, kebiasaan merokok, kadar HbA1c, dan kadar glukosa darah.

Pemilihan dataset ini didasari oleh beberapa pertimbangan:

1. ukurannya yang memadai (100.000 baris) untuk merepresentasikan skenario big data
2. ketersediaan variabel yang relevan secara klinis terhadap diabetes
3. adanya masalah kualitas data yang realistis sehingga menuntut tahap preprocessing yang bermakna.

Karakteristik Dataset:

Atribut	Nilai
Jumlah Row	100.000 baris
Jumlah Kolom	9 Kolom
Format File	CSV
Data Duplikat	7472
Missing Values	0
Nama Dataset	diabetes_prediction_dataset.csv

Karakteristik Fitur/Kolom:

Nama Kolom	Tipe Data	Deskripsi
gender	Kategorikal	Jenis kelamin: Male, Female
age	Integer	Usia pasien
hypertension	Binary (0/1)	Riwayat hipertensi: 1 = ya, 0 = tidak

Nama Kolom	Tipe Data	Deskripsi
heart_disease	Binary (0/1)	Riwayat penyakit jantung: 1 = ya, 0 = tidak
smoking_history	Kategorikal	Riwayat merokok: current, former, never, ever, no info
bmi	Float	Body Mass Index — indikator berat badan relatif terhadap tinggi badan
HbA1c_level	Float	Kadar hemoglobin terglikasi (%) — marker kontrol gula darah jangka panjang
blood_glucose_level	Integer	Kadar glukosa darah (mg/dL)
diabetes	Binary (0/1)	Variabel target: 1 = diabetes, 0 = tidak diabetes

3.1.2 Data Ingestion

Tahap *data ingestion* menjadi gerbang awal dalam siklus pengolahan data, di mana dataset mentah diimpor ke dalam *Apache Spark* yang telah diinisialisasi sebelumnya. Pada fase ini, fokus utama terletak pada penilaian awal terhadap kualitas data guna memahami karakteristik dasarnya sebelum melangkah lebih jauh. Proses peninjauan ini dilakukan untuk memeriksa struktur umum data secara menyeluruh, mulai dari melihat volume baris dan kolom, mengidentifikasi keberadaan nilai yang hilang atau duplikat, hingga memastikan kesesuaian tipe data pada setiap variabel.

Pemeriksaan awal tersebut berfungsi sebagai fondasi penting untuk memastikan bahwa data yang masuk berada dalam kondisi yang layak untuk diolah oleh *Apache Spark*. Dengan memperoleh gambaran umum mengenai validitas dataset sejak dini, potensi kendala teknis atau bias pada proses analisis dapat diminimalkan. Setelah seluruh karakteristik dasar data ini tergambar dan terkonfirmasi dengan baik, barulah aliran informasi siap dialirkan menuju tahap pemrosesan (*processing*) untuk analisis yang lebih mendalam.

3.1.3 Processing

Tahap *processing* merupakan fase inti di mana data mentah mulai diolah dan diubah menjadi informasi yang terstruktur menggunakan *Apache Spark* (*PySpark*). Proses ini diawali dengan

eksplorasi data secara menyeluruh untuk memahami pola dan karakteristik dasar dari dataset. Selanjutnya, pengerjaan difokuskan pada tahap pembersihan. Langkah ini mencakup transformasi nilai kategorikal pada kolom *smoking_history*, serta perbaikan format penulisan angka desimal agar bisa dilakukan analisis. Penyesuaian tersebut merupakan syarat mutlak agar sistem dapat membaca dan memproses informasi secara akurat tanpa adanya kesalahan format.

Selain pembersihan dasar, *feature engineering* juga diterapkan pada beberapa fitur, seperti *bmi*, *blood_glucose_level*, *hbA1c_level*, dan *risk_score*. Proses tersebut bertujuan untuk mengekstraksi dan membentuk variabel baru yang lebih relevan untuk kebutuhan analisis lanjutan. Sebagai langkah penyempurnaan struktur data, dilakukan penambahan kolom baru yaitu *patient ID* pada setiap rekaman. Pemberian pengenalan khusus ini dirancang untuk memastikan rekam jejak yang spesifik, sehingga proses pelacakan, pengelolaan, dan identifikasi data dapat berjalan dengan lebih terorganisasi dan efisien selama keseluruhan alur analisis berlangsung. dan juga kami juga melakukan beberapa analisis seperti analisis diabetes

3.1.4 Storage(SQL + NoSQL)

Setelah tahap processing selesai, data kemudian disimpan menggunakan dua jenis database. Pertama, data klinis yang sudah terstruktur disimpan ke dalam database relasional Supabase (PostgreSQL). Penyimpanan ini digunakan untuk menjaga data tetap rapi dan terorganisir, terutama data kesehatan utama dan skor risiko pasien, sehingga proses pencarian dan analisis data dapat dilakukan dengan lebih cepat dan mudah.

Selain itu, sistem penyimpanan NoSQL juga digunakan dengan memanfaatkan MongoDB. Data yang berkaitan dengan gaya hidup pasien dan riwayat penyakit disimpan dalam bentuk dokumen pada koleksi profil pasien. Pendekatan ini dipilih karena MongoDB lebih fleksibel dalam menangani data yang memiliki struktur berbeda atau dapat bertambah sewaktu-waktu, terutama untuk data profil pengguna yang bersifat dinamis.

Agar kedua database dapat saling terhubung, dilakukan proses integrasi data lintas sistem (Cross-System Analysis). Pada tahap ini, data klinis dari PostgreSQL digabungkan dengan data gaya hidup dari MongoDB menggunakan ID pasien yang sama. Hasil penggabungan tersebut menghasilkan kategori risiko pasien, mulai dari risiko rendah hingga kritis, berdasarkan skor risiko dan penyakit penyerta yang dimiliki pasien.

Sebagai tahap akhir, hasil analisis gabungan tersebut kemudian disimpan kembali secara bersamaan ke Supabase dan MongoDB. Tujuannya agar data tetap sinkron dan siap digunakan untuk kebutuhan visualisasi maupun analisis lanjutan.

3.1.5 Visualization

Tahap visualisasi merupakan langkah krusial untuk mentransformasikan dataset yang telah terintegrasi menjadi representasi grafis yang intuitif. Pada fase ini, eksplorasi difokuskan untuk memvisualisasikan gambaran umum dari profil kesehatan populasi secara visual. visualisasi tersebut mencakup distribusi indikator klinis dasar, seperti indeks massa tubuh (BMI), kadar HbA1c, dan tingkat glukosa darah, serta komposisi kategori risiko pasien secara keseluruhan.

Melalui pendekatan visual ini, pola tersembunyi dan korelasi antar metrik kesehatan, seperti dampak riwayat gaya hidup maupun penyakit penyerta terhadap lonjakan skor risiko, dapat diidentifikasi dengan jauh lebih jelas. Secara garis besar, tahapan visualisasi ini berfungsi untuk menyederhanakan kompleksitas hasil pengolahan data lintas sistem (*cross-system analytics*) menjadi wawasan yang mudah diinterpretasikan, sekaligus memvalidasi kualitas data akhir sebelum digunakan untuk pengambilan keputusan lanjutan.

3.2 Komponen Teknologi

Berikut adalah komponen utama yaitu data source, processing, storage dan visualization. Komponen utama tersebut, menggunakan teknologi sebagai berikut.

Komponen	Teknologi	Fungsi
Data Source	Kaggle	Sebagai sumber dataset Diabetes.
Data Processing	Python, Apache Spark dan Pandas	Untuk melakukan preprocessing, transformation dan untuk menganalisis data.
SQL Storage	PostgreSQL	Untuk menyimpan data structured.
NoSQL Storage	MongoDB	Untuk menyimpan data semi structured.
Connector	SQLAlchemy dan	Sebagai koneksi antara

	PyMongo	Python dengan database
Visualization	Streamlit	Untuk membuat dashboard dan visualisasi yang interaktif
Development Environment	Jupyter Notebook dan Visual Studio Code	Untuk pengembangan sistem.

BAB IV


IMPLEMENTASI

4.1 Metodologi

Metodologi yang digunakan adalah Pipeline yang digunakan untuk membangun sistem Big Data yang mampu mengolah data dalam jumlah besar secara terstruktur, efisien, dan scalable menggunakan ekosistem Apache Spark serta kombinasi penyimpanan SQL (PostgreSQL) dan NoSQL (MongoDB). Tujuan utamanya adalah untuk mendukung analisis faktor risiko diabetes berdasarkan variabel penting seperti BMI, hipertensi, riwayat merokok, dan kadar glukosa darah, sehingga proses analisis tidak hanya cepat tetapi juga dapat menangani data yang kompleks dan beragam.

Penggunaan pipeline ini memungkinkan setiap tahap pengolahan data dilakukan secara sistematis, mulai dari pengambilan data, pembersihan, transformasi, hingga penyimpanan dan analisis lanjutan. Integrasi SQL dan NoSQL digunakan agar data terstruktur dan semi-terstruktur dapat dikelola secara bersamaan, sementara Apache Spark berperan dalam mempercepat pemrosesan data skala besar secara distributed computing. Dengan alur ini, sistem dapat menghasilkan insight yang lebih akurat dan real-time untuk memahami pola serta faktor risiko diabetes, yang kemudian ditampilkan melalui dashboard interaktif agar mudah dipahami oleh pengguna.

Alur metodologi pipeline ini dimulai dari dataset Kaggle sebagai sumber data, kemudian dilakukan data ingestion untuk memasukkan data ke sistem. Setelah itu data diproses melalui data cleaning & preprocessing untuk membersihkan data, dilanjutkan feature engineering untuk membentuk fitur yang lebih informatif. Data kemudian disimpan menggunakan PostgreSQL (SQL) dan MongoDB (NoSQL) sesuai karakteristiknya, lalu diintegrasikan melalui SQL & NoSQL integration agar dapat dianalisis secara menyeluruh. Tahap berikutnya adalah analytics & insight generation untuk menghasilkan pola dan kesimpulan, dan hasil akhirnya ditampilkan dalam dashboard interaktif menggunakan Streamlit agar mudah dipahami pengguna.



4.2 Alur Pipeline

4.2.1 Inisiasi Spark

Proses ini bertujuan untuk menyiapkan Apache Spark sebagai engine utama dalam pengolahan big data pada pipeline analisis diabetes. Inisialisasi dilakukan dengan membuat SparkSession sebagai pusat kontrol pemrosesan data, kemudian sistem diatur agar berjalan pada komputer lokal menggunakan seluruh core CPU yang tersedia sehingga komputasi dapat dilakukan secara paralel dan lebih cepat. Selain itu, ditambahkan driver PostgreSQL agar Spark dapat terhubung dengan database, serta dilakukan pengaturan memori driver dan executor untuk menjaga kestabilan saat memproses dataset berukuran besar.

Selanjutnya, diterapkan beberapa konfigurasi optimasi seperti Adaptive Query Execution untuk meningkatkan efisiensi eksekusi query, pengaturan jumlah partisi shuffle untuk distribusi data yang lebih optimal, serta aktivasi Apache Arrow agar pertukaran data antara PySpark dan Pandas menjadi lebih cepat. Setelah konfigurasi selesai, SparkSession dijalankan sebagai engine utama, log diatur hanya menampilkan error penting, dan sistem menampilkan informasi versi Spark, nama aplikasi, serta mode eksekusi sebagai tanda bahwa

proses inisialisasi berhasil dilakukan. Hasil dari tahap ini adalah sebagai berikut.

```
✓ SparkSession berhasil dibuat sebagai ENGINE UTAMA!  
Spark version : 4.1.1  
App name      : BIGDATA_Diabetes_Pipeline_SparkFirst  
Master        : local[*]
```

4.2.2 Ingestion

Tahap ini bertujuan untuk melakukan ingestion data, yaitu proses membaca dan memasukkan dataset ke dalam Apache Spark agar data dapat diproses lebih lanjut pada pipeline big data. Dataset dibaca menggunakan `spark.read` dengan beberapa pengaturan, seperti `header='true'` untuk menjadikan baris pertama sebagai nama kolom, `sep=';` untuk menentukan pemisah data, serta `encoding='UTF-8'` agar karakter dapat terbaca dengan benar. Selain itu, `inferSchema='false'` digunakan agar seluruh data awal dibaca sebagai string sehingga proses validasi dan casting tipe data dapat dilakukan secara lebih terkontrol pada tahap preprocessing berikutnya. Setelah data berhasil dimuat, sistem melakukan pengecekan terhadap kemungkinan adanya karakter BOM (`\u0000`) pada nama kolom pertama, kemudian menghapusnya agar tidak menyebabkan masalah saat proses analisis data.

Selanjutnya, sistem menghitung jumlah baris dan kolom dataset untuk mengetahui dimensi data yang berhasil di-load. Informasi nama kolom dan jumlah partisi Spark juga ditampilkan untuk memastikan data telah terdistribusi dengan baik pada proses komputasi paralel. Setelah itu, `printSchema()` digunakan untuk menampilkan struktur schema awal dataset sebelum dilakukan proses casting tipe data, sedangkan `show(5, truncate=False)` digunakan untuk menampilkan lima baris pertama sebagai sampel data agar isi dataset dapat diverifikasi secara awal. Dengan proses ini, dataset berhasil dimasukkan ke lingkungan Apache Spark dan siap digunakan pada tahap eksplorasi serta preprocessing data berikutnya. Hasil dari tahap ini adalah sebagai berikut.

```

✅ Ingestion via Spark berhasil!
Dimensi : 100,000 baris x 9 kolom
Kolom   : ['gender', 'age', 'hypertension', 'heart_disease', 'smoking_history', 'bmi', 'hbA1c_level', 'blood_glucose_level', 'diabetes']
Partisi  : 1

Schema (sebelum casting):
root
 |-- gender: string (nullable = true)
 |-- age: string (nullable = true)
 |-- hypertension: string (nullable = true)
 |-- heart_disease: string (nullable = true)
 |-- smoking_history: string (nullable = true)
 |-- bmi: string (nullable = true)
 |-- hbA1c_level: string (nullable = true)
 |-- blood_glucose_level: string (nullable = true)
 |-- diabetes: string (nullable = true)

Sample 5 baris:
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|gender|age|hypertension|heart_disease|smoking_history|bmi |hbA1c_level|blood_glucose_level|diabetes|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|Male  |20 |0          |0           |former        |23,33|6         |158           |0       |
|Female|20 |0          |0           |current       |30,94|5         |90            |0       |
|Female|20 |0          |0           |never         |38,45|4         |90            |0       |
|Female|20 |0          |0           |never         |27,32|3,5       |90            |0       |
|Female|20 |0          |0           |current       |27,32|3,5       |200           |0       |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows

```

4.2.3 Processing

4.2.3.1 Eksplorasi Awal Data (via Spark)

Tahap ini bertujuan untuk melakukan eksplorasi awal dataset guna memahami kondisi dan karakteristik data sebelum masuk ke proses preprocessing. Pada tahap ini, sistem memeriksa kualitas data dengan menghitung jumlah missing values pada setiap kolom menggunakan fungsi `isNull()` dan pengecekan string kosong (`"`). Proses tersebut dilakukan agar dapat diketahui apakah terdapat data yang hilang atau tidak lengkap yang berpotensi memengaruhi hasil analisis maupun proses machine learning. Selain itu, eksplorasi awal juga membantu memahami struktur dan distribusi data sehingga proses pembersihan data dapat dilakukan secara lebih tepat.

Selanjutnya, sistem menampilkan distribusi data pada kolom diabetes menggunakan `groupBy()` dan `count()` untuk melihat jumlah masing-masing kategori, sehingga dapat diketahui keseimbangan data antara pasien diabetes dan non-diabetes. Distribusi pada kolom `smoking_history` juga dianalisis untuk mengetahui kategori riwayat merokok yang paling banyak muncul dalam dataset. Selain itu, sistem menampilkan beberapa sampel nilai pada kolom `bmi` untuk memeriksa format data asli, termasuk penggunaan tanda koma pada nilai numerik. Melalui proses eksplorasi awal ini, kondisi dataset dapat dipahami secara lebih menyeluruh sehingga mempermudah tahap preprocessing dan analisis data berikutnya. Hasil dari tahap ini adalah sebagai berikut.

```

=====
EKSPLORASI AWAL DATASET
=====
Missing Values per Kolom:
+-----+-----+-----+-----+-----+-----+-----+-----+
|gender|age|hypertension|heart_disease|smoking_history|bmi|hbA1c_level|blood_glucose_level|diabetes|
+-----+-----+-----+-----+-----+-----+-----+-----+
|      0| 0|          0|          0|          0| 0| 0|          0|          0|
+-----+-----+-----+-----+-----+-----+-----+-----+

Sample Distribusi diabetes:
+-----+-----+
|diabetes|count|
+-----+-----+
|      0|91500|
|      1| 8500|
+-----+-----+

Distribusi smoking_history:
+-----+-----+
|smoking_history|count|
+-----+-----+
|          never|77358|
|          former|11333|
|          current|11309|
+-----+-----+

Sample BMI (format asli dengan koma):
+-----+
|  bmi|
+-----+
|23,33|
|30,94|
|38,45|
|27,32|
|27,32|
+-----+
only showing top 5 rows

```

4.2.3.2 Data Cleaning & Preprocessing (via Spark)

Tahap ini bertujuan untuk melakukan data cleaning dan preprocessing agar dataset menjadi lebih bersih, konsisten, dan siap digunakan pada proses analisis maupun machine learning. Proses dimulai dengan melakukan casting tipe data pada beberapa kolom seperti age, hypertension, heart_disease, diabetes, dan blood_glucose_level menjadi tipe integer, sedangkan kolom bmi dan hbA1c_level diubah menjadi tipe double. Sebelum dilakukan casting pada data numerik desimal, tanda koma pada nilai data terlebih dahulu diganti menjadi titik menggunakan `regexp_replace()` agar format data sesuai dengan standar numerik yang dapat dibaca Spark. Setelah itu, sistem membuat patient_id unik untuk setiap data pasien menggunakan kombinasi huruf “P” dan nomor urut otomatis sehingga setiap baris data memiliki identitas yang berbeda dan lebih mudah dikelola.

Selanjutnya, dilakukan standarisasi pada kolom smoking_history dengan mengelompokkan beberapa kategori yang memiliki makna serupa menjadi kategori yang lebih konsisten, seperti

ever dan not current yang diubah menjadi former, serta No Info yang diubah menjadi never. Proses ini dilakukan agar data kategorikal lebih rapi dan mudah dianalisis. Setelah standarisasi selesai, sistem menghapus data duplikat menggunakan dropDuplicates() serta menghapus baris yang memiliki nilai kosong pada kolom penting seperti bmi, hbA1c_level, blood_glucose_level, dan age menggunakan dropna(). Terakhir, sistem menampilkan jumlah data sebelum dan sesudah cleaning, distribusi kategori smoking_history setelah standarisasi, struktur schema terbaru, serta lima sampel data untuk memastikan proses preprocessing berhasil dilakukan dengan baik. Hasil dari tahap ini adalah sebagai berikut.

```

✓ Cleaning via Spark selesai!
Baris sebelum: 100,000
Baris sesudah: 100,000
Dihapus      : 0

Distribusi smoking_history sesudah standarisasi:
+-----+-----+
|smoking_history|count|
+-----+-----+
|      current|11309|
|       former|11333|
|       never|77358|
+-----+-----+

Schema setelah casting:
root
 |-- gender: string (nullable = true)
 |-- age: integer (nullable = true)
 |-- hypertension: integer (nullable = true)
 |-- heart_disease: integer (nullable = true)
 |-- smoking_history: string (nullable = false)
 |-- bmi: double (nullable = true)
 |-- hbA1c_level: double (nullable = true)
 |-- blood_glucose_level: integer (nullable = true)
 |-- diabetes: integer (nullable = true)
 |-- patient_id: string (nullable = false)

Sample 5 baris:
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|gender|age|hypertension|heart_disease|smoking_history|bmi|hbA1c_level|blood_glucose_level|diabetes|patient_id|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|Male  |20 |0           |0            |former         |23.33|6.0        |158                |0       |P000001  |
|Female|20 |0           |0            |current        |30.94|5.0        |90                 |0       |P000002  |
|Female|20 |0           |0            |never          |38.45|4.0        |90                 |0       |P000003  |
|Female|20 |0           |0            |never          |27.32|3.5        |90                 |0       |P000004  |
|Female|20 |0           |0            |current        |27.32|3.5        |200                |0       |P000005  |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows

```

4.2.3.3 Feature Engineering (via Spark)

Tahap ini bertujuan untuk melakukan feature engineering, yaitu proses membuat fitur atau variabel baru dari data yang sudah dibersihkan agar informasi dalam dataset menjadi lebih mudah dianalisis dan lebih bermanfaat untuk proses machine learning. Pada tahap ini, sistem membuat beberapa kategori baru berdasarkan nilai tertentu, seperti bmi_cat untuk mengelompokkan BMI ke dalam kategori Underweight, Normal, Overweight, dan Obese. Selain itu, dibuat juga kategori gluc_cat berdasarkan kadar gula darah serta hbA1c_cat berdasarkan nilai HbA1c untuk mengidentifikasi kondisi normal, pre-diabetes, atau diabetes. Sistem juga membentuk age_group untuk mengelompokkan usia pasien ke dalam beberapa rentang umur sehingga analisis data berdasarkan kelompok usia menjadi lebih mudah

dilakukan.

Selanjutnya, sistem membuat fitur baru bernama `risk_score` yang digunakan untuk mengukur tingkat risiko diabetes pada setiap pasien. Nilai skor dihitung berdasarkan beberapa faktor risiko, seperti obesitas, hipertensi, penyakit jantung, riwayat merokok, kadar gula darah tinggi, dan nilai HbA1c tinggi. Setiap kondisi risiko akan menambah nilai skor sehingga semakin tinggi skor yang dimiliki pasien, maka semakin tinggi pula potensi risiko diabetesnya. Setelah seluruh fitur baru berhasil dibuat, dataset disimpan sementara menggunakan `cache()` agar proses akses data berikutnya menjadi lebih cepat. Terakhir, sistem menampilkan jumlah total baris, jumlah kolom terbaru, serta beberapa sampel data untuk memastikan bahwa proses feature engineering berhasil dilakukan dengan baik. Hasil dari tahap ini adalah sebagai berikut.

```
Memulai Feature Engineering via Spark...
✅ Feature Engineering via Spark selesai!
Total baris : 100,000
Total kolom : 15
```

patient_id	bmi	bmi_cat	gluc_cat	hba1c_cat	risk_score	diabetes
P000001	23.33	Normal	Diabetic-range (>...	Pre-diabetic (5.7...	2	0
P000002	30.94	Obese	Normal (<100)	Normal (<5.7)	2	0
P000003	38.45	Obese	Normal (<100)	Normal (<5.7)	1	0
P000004	27.32	Overweight	Normal (<100)	Normal (<5.7)	0	0
P000005	27.32	Overweight	Diabetic-range (>...	Normal (<5.7)	2	0

only showing top 5 rows

4.2.3.4 Ringkasan Hasil Preprocessing

Tahap ini bertujuan untuk menampilkan ringkasan hasil preprocessing guna memastikan bahwa seluruh proses pembersihan data dan feature engineering telah berhasil dilakukan dengan baik. Pada tahap ini, sistem menampilkan jumlah akhir baris dan kolom dataset setelah melalui proses cleaning, standarisasi, dan penambahan fitur baru. Informasi tersebut digunakan untuk mengetahui ukuran akhir dataset yang siap digunakan pada tahap analisis maupun penyimpanan data. Selain itu, sistem juga menampilkan struktur schema DataFrame Spark menggunakan `printSchema()` agar tipe data setiap kolom dapat diverifikasi kembali setelah proses preprocessing selesai dilakukan.

Selanjutnya, sistem menampilkan distribusi kategori pada kolom `smoking_history` menggunakan `groupBy()` dan `count()` untuk memastikan hasil standarisasi kategori telah berjalan dengan benar. Setelah itu, lima sampel data ditampilkan menggunakan `show(5, truncate=False)` agar isi dataset akhir dapat diperiksa secara langsung. Melalui tahap

ringkasan ini, pengguna dapat memastikan bahwa data telah bersih, konsisten, memiliki struktur yang sesuai, dan siap digunakan pada proses penyimpanan database, analisis, serta visualisasi data berikutnya. Hasil dari tahap ini adalah sebagai berikut.

✅ Preprocessing selesai!
Dimensi akhir : 100,000 baris x 15 kolom

Schema DataFrame Spark akhir:

```
root
|-- gender: string (nullable = true)
|-- age: integer (nullable = true)
|-- hypertension: integer (nullable = true)
|-- heart_disease: integer (nullable = true)
|-- smoking_history: string (nullable = false)
|-- bmi: double (nullable = true)
|-- hbA1c_level: double (nullable = true)
|-- blood_glucose_level: integer (nullable = true)
|-- diabetes: integer (nullable = true)
|-- patient_id: string (nullable = false)
|-- bmi_cat: string (nullable = false)
|-- gluc_cat: string (nullable = false)
|-- hbA1c_cat: string (nullable = false)
|-- age_group: string (nullable = false)
|-- risk_score: integer (nullable = true)
```

Distribusi smoking_history:

```
+-----+
|smoking_history|count|
+-----+
|      current|11309|
|      former|11333|
|      never|77358|
+-----+
```

Distribusi smoking_history:

```
+-----+
|smoking_history|count|
+-----+
|      current|11309|
|      former|11333|
|      never|77358|
+-----+
```

Sample 5 baris:

```
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|gender|age|hypertension|heart_disease|smoking_history|bmi|hbA1c_level|blood_glucose_level|diabetes|patient_id|bmi_cat|gluc_cat|hbA1c_cat|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|Male|20|0|0|former|23.33|6.0|158|0|P000001|Normal|Diabetic-range (>=126)|Pre-d
iabetic (5.7-6.4)|<30 Tahun|2|
|Female|20|0|0|current|30.94|5.0|90|0|P000002|Obese|Normal (<100)|Norma
1 (<5.7)|<30 Tahun|2|
|Female|20|0|0|never|38.45|4.0|90|0|P000003|Obese|Normal (<100)|Norma
1 (<5.7)|<30 Tahun|1|
|Female|20|0|0|never|27.32|3.5|90|0|P000004|Overweight|Normal (<100)|Norma
1 (<5.7)|<30 Tahun|0|
|Female|20|0|0|current|27.32|3.5|200|0|P000005|Overweight|Diabetic-range (>=126)|Norma
1 (<5.7)|<30 Tahun|2|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
```

only showing top 5 rows

4.2.4 Storage

4.2.4.1 Penyimpanan Data Hasil Preprocessing ke PostgreSQL Menggunakan Spark JDBC

Tahap ini bertujuan untuk melakukan penyimpanan data hasil preprocessing ke dalam database PostgreSQL menggunakan koneksi JDBC dari Apache Spark. Pada proses ini, sistem terlebih dahulu memilih kolom-kolom penting yang akan disimpan ke database, seperti informasi pasien, kategori BMI, kategori gula darah, kategori HbA1c, kelompok usia, skor risiko, dan status diabetes. Setelah itu, jumlah total data dihitung untuk memastikan banyaknya baris yang akan dikirim ke PostgreSQL. Proses penyimpanan dilakukan menggunakan `.write.format('jdbc')` dengan menghubungkan Spark ke PostgreSQL melalui URL database, username, password, dan driver PostgreSQL. Selain itu, pengaturan `numPartitions='4'` digunakan agar proses penulisan data dapat dilakukan secara paralel sehingga lebih cepat, sedangkan `batchsize='5000'` digunakan untuk mengirim data dalam beberapa batch agar proses penyimpanan lebih efisien dan stabil.

Selanjutnya, mode overwrite digunakan sehingga tabel `Kategori_umur` pada PostgreSQL akan diperbarui dengan data terbaru setiap kali proses dijalankan. Setelah proses penyimpanan selesai, sistem melakukan validasi dengan membaca kembali tabel dari PostgreSQL menggunakan Spark JDBC untuk memastikan data berhasil tersimpan dengan benar. Data yang berhasil dibaca kembali kemudian dihitung jumlah barisnya dan ditampilkan beberapa sampel data menggunakan `show(3)` sebagai bukti bahwa proses integrasi antara Apache Spark dan PostgreSQL berjalan dengan baik. Melalui tahap ini, data hasil preprocessing telah tersimpan secara terstruktur di database relasional dan siap digunakan untuk analisis maupun integrasi sistem berikutnya. Hasil dari tahap ini adalah sebagai berikut.

```
Menulis 100,000 baris ke PostgreSQL (tabel: Kategori_umur)...
PostgreSQL berhasil! Kategori_umur = 100,000 baris
```

patient_id	gender	age	bmi	hbA1c_level	blood_glucose_level	hypertension	heart_disease	smoking_history	bmi_cat	gluc_cat	hba1c_cat
P000001	Male	20	23.33	6.0	158	0	0	former	Normal	Diabetic-range (>...)	Pre-diabetic (5.7...)
P000002	Female	20	30.94	5.0	90	0	0	current	Obese	Normal (<100)	Normal (<5.7)
P000003	Female	20	38.45	4.0	90	0	0	never	Obese	Normal (<100)	Normal (<5.7)

only showing top 3 rows

4.2.4.2 Penyimpanan Data Hasil Preprocessing ke MongoDB Menggunakan PyMongo

Tahap ini bertujuan untuk menyimpan data hasil preprocessing ke dalam MongoDB menggunakan PyMongo sebagai database NoSQL. Sistem terlebih dahulu memilih beberapa kolom penting seperti `patient_id`, `smoking_history`, `hypertension`, dan `heart_disease`, kemudian mengubah Spark DataFrame menjadi Pandas DataFrame agar lebih mudah diproses. Setelah itu, setiap baris data dibentuk menjadi dokumen JSON bertingkat (nested document) yang berisi informasi riwayat medis dan gaya hidup pasien sehingga struktur data menjadi lebih fleksibel dan terorganisir.

Selanjutnya, sistem membuat koneksi ke MongoDB dan mengakses collection `patient_profiles`. Collection lama dihapus menggunakan `drop()` agar data baru tidak tercampur dengan data sebelumnya. Setelah itu, seluruh dokumen disimpan secara massal menggunakan `insert_many()` agar proses penyimpanan lebih efisien. Terakhir, sistem melakukan validasi dengan menghitung jumlah dokumen yang berhasil tersimpan dan menampilkan satu contoh dokumen untuk memastikan data telah masuk ke MongoDB dengan struktur yang sesuai. Hasil dari tahap ini adalah sebagai berikut.

```
🕒 Menyimpan 100,000 dokumen ke MongoDB...
✅ MongoDB berhasil! 100,000 dokumen di collection patient_profiles.
Sample dokumen pertama:
{'lifestyle': {'smoking_status': 'former'},
 'medical_history': {'heart_disease_status': 0, 'hypertension_status': 0},
 'patient_id': 'P000001'}
```

4.2.4.3 Integrasi Data PostgreSQL dan MongoDB untuk Cross-System Analysis

Tahap ini bertujuan untuk melakukan integrasi data antara PostgreSQL dan MongoDB agar analisis dapat dilakukan secara lebih lengkap melalui pendekatan cross-system analysis. Pada Layer 1, sistem membaca data klinis dari PostgreSQL menggunakan Spark JDBC, kemudian membuat temporary view agar data dapat dianalisis menggunakan Spark SQL. Proses ini menghasilkan statistik klinis berdasarkan `risk_score`, seperti jumlah pasien, total pasien diabetes, persentase prevalensi diabetes, rata-rata BMI, HbA1c, dan kadar glukosa darah. Selanjutnya pada Layer 2, sistem mengambil data lifestyle dari MongoDB menggunakan PyMongo dan melakukan agregasi berdasarkan `smoking_history`. Dari proses ini dihasilkan informasi jumlah pasien, total hipertensi, total penyakit jantung, serta persentase pasien hipertensi dan

penyakit jantung pada setiap kategori riwayat merokok.

Pada Layer 3, dilakukan proses integrasi data antara PostgreSQL dan MongoDB menggunakan Pandas merge berdasarkan `patient_id`. Data hasil gabungan kemudian digunakan untuk membentuk kategori risiko baru (`risk_category`) seperti LOW, MEDIUM, HIGH, dan CRITICAL berdasarkan kombinasi nilai `risk_score`, hipertensi, dan penyakit jantung. Setelah proses analisis selesai, hasil integrasi disimpan kembali ke PostgreSQL dalam tabel `cross_system_analytics` dan ke MongoDB dalam collection dengan nama yang sama. Terakhir, sistem menampilkan distribusi kategori risiko serta memberikan konfirmasi bahwa proses integrasi SQL dan NoSQL berhasil dilakukan. Tahap ini memungkinkan analisis data dilakukan secara lebih komprehensif dengan menggabungkan kekuatan database relasional dan NoSQL dalam satu pipeline big data. Hasil dari tahap ini adalah sebagai berikut.

```

=====
LAYER 1: PostgreSQL – Statistik Klinis per Risk Score
=====
7 kelompok risk_score dari PostgreSQL:
+-----+-----+-----+-----+-----+-----+-----+
|risk_score|total_pasien|total_diabetes|prevalensi_pct|rata_bmi|rata_hba1c|rata_glukosa|
+-----+-----+-----+-----+-----+-----+-----+
|0|13935|0|0.0|24.13|5.16|88.7|
|1|42361|736|1.7|25.17|5.27|138.2|
|2|28131|2558|9.1|28.92|5.69|148.2|
|3|11456|2966|25.9|32.55|6.08|159.8|
|4|3385|1714|50.6|34.67|6.66|173.2|
|5|665|473|71.1|35.19|7.08|178.1|
|6|67|53|79.1|37.07|7.27|190.7|
+-----+-----+-----+-----+-----+-----+-----+

=====
LAYER 2: MongoDB – Profil Lifestyle per Smoking Status
=====
3 kelompok smoking_history dari MongoDB:
smoking_history total_pasien total_hipertensi total_jantung pct_hipertensi pct_jantung
0 never 77358 4895 2312 6.3 3.0
1 former 11333 1547 1066 13.7 9.4
2 current 11309 1043 564 9.2 5.0

=====
LAYER 3: Cross-System JOIN (Pandas merge SQL + NoSQL)
=====
Baris setelah JOIN SQL x NoSQL: 100,000
Distribusi Risk Category:
risk_category
LOW 55521
MEDIUM 25136
HIGH 14925
CRITICAL 4418

✅ Tersimpan PostgreSQL: tabel cross_system_analytics
✅ Tersimpan MongoDB: koleksi cross_system_analytics (100,000 dokumen)

✅ Integrasi SQL ↔ NoSQL selesai!

```

4.2.5 Visualization

4.2.5.1 Implementasi Empat Query Utama Menggunakan Apache Spark SQL

Tahap ini bertujuan untuk melakukan analisis data menggunakan Apache Spark SQL melalui empat query utama guna menghasilkan insight terkait kondisi diabetes pasien. Proses dimulai dengan membuat temporary view bernama `transaksi_spark` dari DataFrame `sdf_fe` sehingga data dapat diakses dan dianalisis menggunakan sintaks SQL. Query pertama digunakan untuk menganalisis prevalensi diabetes berdasarkan kategori BMI (`bmi_cat`) dengan menampilkan

jumlah pasien, total pasien diabetes, persentase prevalensi, rata-rata BMI, dan rata-rata kadar glukosa darah. Query kedua menganalisis prevalensi diabetes berdasarkan kelompok usia dengan mengelompokkan pasien ke dalam kategori usia tertentu, kemudian menghitung jumlah pasien, prevalensi diabetes, dan rata-rata nilai HbA1c pada setiap kelompok usia.

Selanjutnya, query ketiga digunakan untuk melihat distribusi pasien berdasarkan risk_score guna mengetahui hubungan tingkat risiko dengan prevalensi diabetes, rata-rata HbA1c, dan kadar glukosa darah. Query keempat menganalisis distribusi kadar glukosa berdasarkan kategori HbA1c (hba1c_cat) untuk melihat hubungan antara kategori HbA1c dengan prevalensi diabetes dan rata-rata kadar glukosa pasien. Setiap hasil query ditampilkan menggunakan show() sehingga insight dari data dapat diamati secara langsung. Melalui tahap ini, Apache Spark SQL dimanfaatkan untuk melakukan analisis data secara cepat dan terstruktur dalam menghasilkan informasi penting terkait kondisi diabetes pasien. Hasil dari tahap ini adalah sebagai berikut.

Temp view terdaftar: transaksi_spark

[1/4] Prevalensi Diabetes per Kategori BMI:

bmi_cat	total_pasien	total_diabetes	prevalensi_pct	rata_bmi	rata_glukosa
Obese	23881	4278	17.9	36.06	144.0
Overweight	45767	3319	7.3	27.31	137.4
Normal	21858	839	3.8	22.07	134.7
Underweight	8494	64	0.8	16.32	133.5

[2/4] Prevalensi Diabetes per Kelompok Usia:

kelompok_usia	total_pasien	total_diabetes	prevalensi_pct	rata_hba1c
<30 Tahun	15683	1362	8.7	5.53
30-50 Tahun	35419	3067	8.7	5.53
>50 Tahun	48898	4071	8.3	5.53

[3/4] Distribusi Pasien per Risk Score:

risk_score	total_pasien	total_diabetes	prevalensi_pct	rata_hba1c	rata_glukosa
0	13935	0	0.0	5.16	88.7
1	42361	736	1.7	5.27	138.2
2	28131	2558	9.1	5.69	148.2
3	11456	2966	25.9	6.08	159.8
4	3385	1714	50.6	6.66	173.2
5	665	473	71.1	7.08	178.1
6	67	53	79.1	7.27	190.7

[4/4] Distribusi Glukosa per Kategori HbA1c:

hba1c_cat	total_pasien	total_diabetes	prevalensi_pct	rata_glukosa
Diabetic-range (>...)	20797	5191	25.0	148.2
Pre-diabetic (5.7...)	41346	3309	8.0	137.7
Normal (<5.7)	37857	0	0.0	132.8

✅ Spark SQL Analysis (4 query) selesai!

4.2.5.2 Implementasi Window Function dan Segmentasi Data Menggunakan Apache Spark

Tahap ini bertujuan untuk melakukan analisis lanjutan menggunakan fitur advanced Apache Spark, yaitu Window Function dan segmentasi data pasien berdasarkan tingkat risiko diabetes. Pada bagian pertama, sistem menggunakan Window Function untuk menghitung running total diabetes pada setiap risk_score berdasarkan kategori glukosa (gluc_cat). Proses ini memungkinkan sistem melihat akumulasi jumlah pasien diabetes secara bertahap di dalam

setiap kelompok risiko. Selain itu, digunakan juga fungsi ROW_NUMBER() untuk memberikan peringkat pada kategori glukosa berdasarkan jumlah kasus diabetes tertinggi dalam masing-masing kelompok risk_score. Hasil analisis kemudian ditampilkan untuk melihat pola distribusi diabetes secara lebih detail.

Pada bagian kedua, sistem melakukan segmentasi pasien ke dalam kategori High Risk, Medium Risk, dan Low Risk berdasarkan nilai risk_score. Dari setiap segmen dihitung jumlah pasien, total pasien diabetes, prevalensi diabetes, rata-rata BMI, HbA1c, dan kadar glukosa darah untuk mengetahui karakteristik masing-masing kelompok risiko. Selanjutnya, sistem juga menampilkan ringkasan kategori risiko hasil integrasi SQL dan NoSQL dari tahap sebelumnya. Setelah seluruh analisis selesai, hasil query Spark diubah ke dalam format Pandas DataFrame agar dapat digunakan pada proses visualisasi menggunakan Plotly dan dashboard Streamlit. Tahap ini membantu menghasilkan analisis yang lebih mendalam terkait distribusi risiko dan pola diabetes pada pasien. Hasil dari tahap ini adalah sebagai berikut.

[1/2] Window Function – Running Total Diabetes per Risk Score:

risk_score	gluc_cat	jumlah_pasien	total_diabetes	running_total_diabetes	rank_dalam_group
0	Normal (<100)	10513	0	0	1
0	Pre-diabetic (100-125)	3422	0	0	2
1	Diabetic-range (>=126)	32424	736	736	1
1	Normal (<100)	7429	0	736	2
1	Pre-diabetic (100-125)	2508	0	736	3
2	Diabetic-range (>=126)	24672	2558	2558	1
2	Normal (<100)	2569	0	2558	2
2	Pre-diabetic (100-125)	890	0	2558	3
3	Diabetic-range (>=126)	10724	2966	2966	1
3	Normal (<100)	551	0	2966	2
3	Pre-diabetic (100-125)	181	0	2966	3
4	Diabetic-range (>=126)	3305	1714	1714	1
4	Normal (<100)	57	0	1714	2
4	Pre-diabetic (100-125)	23	0	1714	3
5	Diabetic-range (>=126)	664	473	473	1
5	Pre-diabetic (100-125)	1	0	473	2
6	Diabetic-range (>=126)	67	53	53	1

[2/2] Patient Segmentation (High / Medium / Low Risk):

patient_segment	jumlah_pasien	total_diabetes	prevalensi_pct	rata_bmi	rata_hba1c	rata_glukosa
High Risk	4117	2240	54.4	34.79	6.73	174.3
Medium Risk	39587	5524	14.0	29.97	5.81	151.5
Low Risk	56296	736	1.3	24.91	5.24	125.9

Risk Category dari Cross-System Analytics:

risk_category	total_pasien	total_diabetes	prevalensi_pct
CRITICAL	4418	2278	51.6
HIGH	14925	3218	21.6
LOW	55521	736	1.3
MEDIUM	25136	2268	9.0

✅ Spark Advanced Analysis selesai!

df (full Pandas) : 100,000 baris – untuk visualisasi Plotly

4.2.5.3 Analytics & Insight

Tahap ini bertujuan untuk menghasilkan ringkasan analisis dan insight utama dari data diabetes yang telah diproses sebelumnya. Pada proses ini, sistem menghitung jumlah total pasien, total pasien diabetes, total pasien non-diabetes, serta persentase prevalensi diabetes dalam dataset. Selain itu, sistem juga menghitung rata-rata nilai BMI, HbA1c, dan kadar glukosa darah khusus pada pasien diabetes untuk melihat kondisi kesehatan pasien secara umum. Seluruh hasil perhitungan tersebut kemudian ditampilkan sebagai ringkasan analisis sistem big data diabetes sehingga pengguna dapat memahami gambaran umum dataset dengan lebih mudah.

Selanjutnya, sistem menampilkan beberapa insight penting hasil analisis data. Insight pertama menunjukkan distribusi risk_score dari hasil analisis Spark untuk melihat hubungan tingkat risiko dengan jumlah pasien diabetes. Insight kedua menganalisis probabilitas diabetes berdasarkan berbagai faktor risiko seperti HbA1c tinggi, kadar glukosa tinggi, hipertensi, penyakit jantung, obesitas, usia lanjut, dan kebiasaan merokok. Dari proses ini dapat diketahui faktor risiko yang paling berpengaruh terhadap diabetes. Insight ketiga menampilkan distribusi kategori risiko hasil integrasi SQL dan NoSQL untuk melihat segmentasi pasien berdasarkan tingkat risiko. Tahap ini membantu menghasilkan informasi yang lebih mudah dipahami dan mendukung proses pengambilan keputusan berbasis data.

1. Ringkasan Analisis Sistem Big Data Diabetes

RINGKASAN ANALISIS SISTEM BIG DATA DIABETES		
Total Pasien	:	100,000
Total Diabetes	:	8,500 (8.5%)
Total Non-Diabetes	:	91,500 (91.5%)
Rata-rata BMI (DM)	:	31.99
Rata-rata HbA1c (DM)	:	6.93%
Rata-rata Glukosa(DM):		194.1 mg/dL

Ringkasan Analisis Sistem Big Data Diabetes menunjukkan bahwa dataset terdiri dari 100.000 pasien dengan total 8.500 pasien diabetes atau sekitar 8,5% dari keseluruhan data, sedangkan 91,5% lainnya termasuk kategori non-diabetes. Hasil ini menunjukkan bahwa mayoritas pasien dalam dataset tidak mengalami diabetes, namun jumlah penderita diabetes masih cukup signifikan untuk dianalisis lebih lanjut.

Selain itu, pasien diabetes memiliki rata-rata BMI sebesar 31,99 yang termasuk kategori obesitas, rata-rata HbA1c sebesar 6,93% yang berada pada rentang diabetes, serta rata-rata kadar glukosa darah sebesar 194,1 mg/dL yang jauh di atas batas normal. Kondisi ini menunjukkan bahwa obesitas, tingginya HbA1c, dan kadar glukosa darah memiliki hubungan kuat dengan diabetes pada dataset tersebut.

2. Insight 1 Distribusi Risk Score (Spark)

Insight 1 – Distribusi Risk Score (Spark):

	risk_score	total_pasien	total_diabetes	prevalensi_pct	rata_hba1c	rata_glukosa
0	0	13935	0	0.0	5.16	88.7
1	1	42361	736	1.7	5.27	138.2
2	2	28131	2558	9.1	5.69	148.2
3	3	11456	2966	25.9	6.08	159.8
4	4	3385	1714	50.6	6.66	173.2
5	5	665	473	71.1	7.08	178.1
6	6	67	53	79.1	7.27	190.7

Pada gambar distribusi risk score menunjukkan jika terjadi tren kenaikan yang konsisten seperti ketika semakin tinggi skor risiko pasien, maka semakin besar juga persentase pasien yang menderita diabetes. Pada risk score 0 pada gambar, sistem menunjukkan jika akurasi sesuai dengan prevalensi 0.0% dari 13.935 pasien yang menunjukkan jika seluruh pasien pada bagian ini sehat. Tetapi pada risk score 3 dengan prevalensi 25.9% dan meningkat hingga 50.6% pada risk score 4, yang berarti ada yang positif diabetes pada kelompok tersebut. Kondisi kritis terjadi pada risk score 6 dengan prevalensi 79.1% yaitu 53 dari 67 pasien.

3. Insight 2 Prevalensi Diabetes per Faktor Risiko

Insight 2 – Prevalensi Diabetes per Faktor Risiko:

	Faktor Risiko	Probabilitas
4	Usia Lanjut (>50 Tahun)	8.325494
6	Perokok Aktif (Current)	10.584490
1	Glukosa Tinggi (≥ 126)	11.829214
5	Obesitas (BMI ≥ 30)	17.985214
0	HbA1c Tinggi ($\geq 6.5\%$)	24.960331
3	Penderita Hipertensi	27.895792
2	Riwayat Penyakit Jantung	32.141045

Pada analisis faktor risiko menjelaskan jika pasien mengalami penyakit jantung atau hipertensi secara bersamaan memiliki korelasi tertinggi terhadap prevalensi diabetes. Riwayat penyakit jantung memiliki prevalensi tinggi sebesar 32.1% lalu urutan selanjutnya yaitu hipertensi sebesar 27.9% yang menunjukkan jika masalah jantung dan hipertensi memiliki risiko munculnya penyakit diabetes. Sementara itu hasil tes laboratorium dan kondisi fisik untuk kelompok pasien dengan HbA1c ($\geq 6.5\%$) berada pada 25.0% dan selanjutnya pada kelompok pasien yang obesitas (BMI ≥ 30) sebesar 18%. Pada kelompok lainnya yaitu pasien dengan kadar gula darah tinggi berada pada 11.8% sedikit diatas untuk kelompok pasien perokok aktif yang mencatat angka 10.6%. Kelompok pasien yang memilki persentase terkecil adalah usia lanjut yaitu sebesar 8.3%.

4. Insight 3 Risk Category (Cross-System)


Insight 3 – Risk Category (Cross-System):

	risk_category	total_pasien	total_diabetes	prevalensi_pct
0	CRITICAL	4418	2278	51.6
1	HIGH	14925	3218	21.6
2	LOW	55521	736	1.3
3	MEDIUM	25136	2268	9.0

Insight 3 menunjukkan hasil segmentasi pasien berdasarkan kategori risiko yang

diperoleh dari integrasi data PostgreSQL dan MongoDB. Kategori CRITICAL memiliki prevalensi diabetes tertinggi, yaitu 51,6%, dengan 2.278 pasien diabetes dari total 4.418 pasien. Hal ini menunjukkan bahwa lebih dari setengah pasien pada kategori kritis mengalami diabetes sehingga kelompok ini memerlukan perhatian dan penanganan medis yang lebih intensif. Kategori HIGH juga menunjukkan prevalensi yang cukup besar sebesar 21,6%, sedangkan kategori MEDIUM memiliki prevalensi 9,0%. Sebaliknya, kategori LOW memiliki prevalensi paling kecil, yaitu hanya 1,3%, meskipun jumlah pasien dalam kategori ini merupakan yang terbesar. Hasil ini menunjukkan bahwa sistem segmentasi risiko yang dibangun berhasil mengelompokkan pasien sesuai tingkat potensi diabetesnya, sehingga dapat membantu proses monitoring dan pengambilan keputusan dalam analisis kesehatan berbasis big data.


4.2.5.4 Visualisasi Distribusi Variabel Numerik



Pada diagram batang yang pertama menampilkan umur dan berapa banyak pasien pada umur tersebut. Frekuensi tertinggi ada pada umur 80-81 tahun terdapat 6.216 pasien dan frekuensi terendah ada pada usia 84-85 tahun yaitu sebanyak 572 pasien. Selanjutnya pada diagram batang kedua menampilkan Bmi atau indeks massa tubuh seseorang, diagram tertinggi dengan nilai 22.5-27.49 dengan frekuensi 46.542 dan diagram dan nilai terendah pada 57.5 - 62.49 dengan frekuensi 112 . Pada diagram ketiga yaitu Hba1c Level atau rata-rata gula darah selama 2 atau 3 bulan terakhir nilai tertinggi pada 6-6.1 dengan frekuensi 16.343 dan terendah yaitu pada nilai 8.8 - 8.9 dengan frekuensi 661. Pada diagram keempat yaitu


diagram Blood Glucose Level atau level kadar glukosa frekuensi tertinggi dengan jumlah 22.360 pada nilai 150-159 dan nilai frekuensi terendah yaitu 674 dengan nilai 300-309.

4.2.5.5 Visualisasi Distribusi Diabetes VS Non-Diabetes




Pada gambar diagram diatas menampilkan distribusi populasi jumlah diabetes dan tidak diabetes. Jumlah pasien yang terkena diabetes yaitu 91.500 pasien dengan persentase 91.5% dan jumlah untuk pasien yang tidak mengalami diabetes adalah 8.500 dengan persentase 8.5%. Dari hasil analisis dapat disimpulkan lebih banyak yang tidak mengalami diabetes.

4.2.5.6 Visualisasi Tren Usia & Gender




Pada visualisasi diatas menunjukkan tren kasus diabetes berdasarkan usia dan gender. Pada usia 80 tahun adalah usia terbanyak kena diabetes bagi jenis kelamin laki-laki dengan jumlah 257 kasus dan bagi jenis kelamin perempuan dengan 265 kasus. Urutan kedua yang terbanyak terkena ada di usia 37 dan 47 tahun dengan jumlah 97 kasus bagi jenis kelamin perempuan dan urutan ketiga yang terbanyak terkena kasus bagi perempuan pada usia 94 tahun. Urutan kedua bagi jenis kelamin laki-laki yaitu pada usia 46 tahun dengan jumlah 91 kasus dan urutan ketiga terbanyak adalah usia 38 tahun dengan jumlah 89 kasus.

4.2.5.7 Visualisasi Diabetes Berdasarkan Kadar Glukosa




Pada diagram batang di samping kanan diatas menunjukkan jumlah prevalensi diabetes per kategori glukosa. Pada diagram tersebut prevalensi tertinggi adalah diabetes dengan diabetes diatas 126 dengan prevalensi 11.8 persen terkena diabetes. Pada diagram batang disamping kiri menunjukkan jumlah pasien per kategori. Kategori terendah dengan status non diabetes adalah pada kategori pre-diabetic dengan kadar gula 100-125 dengan jumlah pasien 7.025. Urutan kedua yaitu pada kategori normal dengan kadar gula dibawah 100 dengan jumlah 21.119. Urutan tertinggi dengan status non diabetes adalah kategori diabetes dengan kadar gula diatas 126 dengan jumlah pasien 63.356. Jumlah pasien yang mengalami diabetes pada kategori diabetes dengan kadar gula diatas 126 adalah 8.500.

4.2.5.7 Visualisasi Analisis HbA1c Berdasarkan Riwayat Merokok




Pada diagram atas menunjukkan berapa persen riwayat perokok terkena kategori HbA1c dan jumlah pasiennya. Kategori terendah untuk status normal ada pada kategori mantan perokok dengan jumlah 34.7% atau sebanyak 3.938 pasien dan urutan kedua yaitu kategori sedang merokok dengan jumlah 37.2% sebanyak 4.207 pasien dan urutan ketiga adalah yang tidak pernah merokok 38.4% sebanyak 29.712 pasien. Status pre-diabetic dengan skala 5.7-6.4 yang terendah adalah mantan perokok yaitu sebanyak 41% dengan jumlah pasien 4.643, urutan kedua adalah yang tidak pernah merokok sebanyak 41.3% atau 31.966 pasien dan urutan ketiga adalah yang sedang merokok sebanyak 41.9% .

4.2.5.8 Visualisasi Matriks Korelasi Fitur Numerik



Pada grafik heatmap diatas menunjukkan indikator laboratorium korelasi hubungan linier terhadap status target pasien. Pada Kadar glukosa darah (blood_glucose_level) tercatat koefisien korelasi tertinggi sebesar 0.42, urutan kedua adalah kadar HbA1c (hbA1c_level) sebesar 0.40, yang berarti keduanya sebagai hal yang menjadi penentu utama diagnosis diabetes secara medis. Selain itu, faktor klinis pada grafik seperti kondisi fisik berupa BMI (0.21) dan penyakit komorbid seperti hipertensi (0.20) terbukti memiliki korelasi positif yang signifikan dalam hal menaikkan risiko diabetes. Tetapi pada nilai korelasi yang kuat dan merata antara variabel risk_score terhadap seluruh parameter medis (berkisar antara 0.35 hingga 0.47) yang berarti jika penilaian risiko yang dirancang telah berhasil.


4.2.5.9 Visualisasi Hieararki Faktor Risiko Berdasarkan Probabilitas Terkena Diabetes




Pada diagram diatas menunjukkan visualisasi hasil analisis dari dataset 100.000 pasien. Distribusi awal populasi menunjukkan terjadi ketidakseimbangan data (*imbalanced data*) yang natural, yaitu bagi penderita Diabetes hanya 8,5% (8.500 pasien) dibandingkan kelompok Non-Diabetes yaitu 91,5% (91.500 pasien). Dari aspek demografi, populasi lebih banyak dari kelompok usia produktif hingga paruh baya (40–60 tahun) dengan indeks massa tubuh (BMI) yang berpusat pada kondisi berat badan normal hingga berlebih. Pada kelompok jenis kelamin laki-laki memiliki prevalensi terkena diabetes yang lebih tinggi sebesar 9,7% dibandingkan jenis kelamin perempuan yang berada di angka 7,6%. Analisis tren berdasarkan usia spesifik menunjukkan tingkat penambahan kasus yang stabil di setiap fase bagi jenis kelamin laki-laki atau perempuan.

4.2.5.10 Visualisasi Hieararki Faktor Risiko Berdasarkan Probabilitas Terkena Diabetes


KPI: PREVALENSI DIABETES (Spark-First Pipeline)




PREVALENSI DIABETES PER KATEGORI BMI (Spark SQL)




SEGMENTASI PASIEN — High/Medium/Low Risk



Prevalensi per Segment



PREVALENSI DIABETES PER RISK CATEGORY (Cross-System SQL+NoSQL)



Analisis terhadap 100.000 sampel pasien menunjukkan gambaran ketidakseimbangan data (*imbalanced data*) yang natural, dengan proporsi kelompok Non-Diabetes sebesar 91,5% (91.500 pasien) dan Diabetes sebesar 8,5% (8.500 pasien). Berdasarkan aspek demografi, kelompok pasien laki-laki tercatat prevalensi diabetes yang lebih tinggi (9,7%) dibandingkan pasien perempuan (7,6%), meskipun secara volume jumlah sampel perempuan jauh lebih

mendominasi di dalam database (54.100 pasien). Analisis tren berdasarkan usia spesifik menunjukkan laju penambahan kasus yang stabil dan beriringan pada rentang usia 20–75 tahun untuk kedua gender, sebelum akhirnya mengalami lonjakan tajam di titik usia 80 tahun akibat adanya kebijakan pembatasan atas (*data capping*) atau akumulasi data lansia oleh sistem manajemen database.


Melalui evaluasi faktor risiko klinis, indikator laboratorium dan penyakit komorbid terbukti menjadi pemicu paling signifikan dalam mendeteksi diabetes. Kadar glukosa darah dan HbA1c menunjukkan korelasi positif searah terkuat (masing-masing sebesar 0,42 dan 0,40), disusul oleh riwayat Penyakit Jantung (probabilitas 32,1%) dan Hipertensi (27,9%) sebagai jenis komorbiditas dengan pengaruh tertinggi. Selain itu, faktor obesitas (BMI) memiliki korelasi positif sebesar 0,21 dengan tingkat keterjangkitan mencapai 17,9%, jauh melampaui kelompok berat badan normal (3,8%). Terakhir, pengujian sistem penilaian risiko (*risk scoring*) berbasis integrasi Spark, SQL, dan NoSQL membuktikan akurasi model yang sangat tinggi. Sistem berhasil mengkonsentrasikan 51,6% penderita diabetes nyata pada kategori *Critical*, sekaligus menyaring populasi sehat pada kategori *Low Risk* dengan margin kesalahan prediksi (*false negative*) yang sangat minimal, yaitu hanya sebesar 1,3%.

BAB V

HASIL DAN ANALISIS

5.1 Hasil Dashboard

5.1.1 Dashboard & KPI




Bagian Dashboard dan Key Performance Indicator (KPI) merupakan tahap akhir dari seluruh proses pengolahan data. Pada dashboard ini, data kesehatan pasien yang telah diproses menggunakan PostgreSQL, MongoDB, dan Apache Spark ditampilkan dalam bentuk visual yang lebih mudah dipahami. Panel KPI pada bagian atas dashboard menampilkan informasi utama seperti total pasien, prevalensi diabetes, rata-rata hbA1c, rata-rata usia pasien, serta jumlah pasien dengan kategori critical. Ringkasan ini membantu pengguna melihat kondisi umum data kesehatan secara cepat tanpa perlu membaca data mentah secara langsung.

Selain menampilkan indikator utama, dashboard juga dilengkapi dengan berbagai visualisasi data seperti diagram gauge, diagram donat, dan diagram batang. Visualisasi tersebut digunakan untuk menunjukkan tingkat prevalensi diabetes, perbandingan pasien diabetes dan non-diabetes, distribusi kategori risiko pasien, serta persentase diabetes pada setiap kategori risiko. Seluruh tampilan dashboard dirancang agar proses analisis data menjadi lebih praktis dan interaktif, sehingga pengguna dapat dengan mudah memahami pola risiko pasien dan

memperoleh insight penting dari hasil integrasi data klinis dan gaya hidup dalam satu sistem terpusat.


5.1.2 EDA

5.1.2.1 Distribusi Numerik




Bagian Distribusi Numerik menyajikan visualisasi sebaran data dari variabel kuantitatif pasien, meliputi metrik klinis utama seperti usia, Indeks Massa Tubuh (BMI), kadar HbA1c, dan tingkat glukosa darah. Melalui representasi grafik penyebaran data, pemetaan ini secara efektif memperlihatkan rentang nilai, titik pemusatan populasi terbanyak, serta pola sebaran secara keseluruhan. Analisis distribusi ini sangat esensial untuk memahami karakteristik dasar dataset secara objektif, sehingga memudahkan proses identifikasi tren kesehatan umum—seperti kelompok usia dominan atau rentang variasi kadar gula darah—serta mendeteksi potensi anomali dan risiko medis yang mungkin memerlukan evaluasi lanjutan.

5.1.2.2 Distribusi Kategorik



Bagian Distribusi Kategorik menyajikan pemetaan visual yang berfokus pada pengelompokan data pasien berdasarkan atribut non-numerik, seperti jenis kelamin, riwayat merokok, serta status penyakit penyerta (hipertensi, penyakit jantung, dan diabetes). Melalui representasi grafik batang (*bar chart*), proporsi dan frekuensi jumlah pasien pada masing-masing kelompok dapat dibandingkan secara langsung dan intuitif. Pemetaan ini sangat esensial untuk memahami komposisi demografis dan gambaran kondisi medis populasi secara umum, sehingga memudahkan pembaca dalam mengidentifikasi kelompok mana yang paling mendominasi serta melihat pola prevalensi risiko kesehatan yang terdapat di dalam dataset.

5.5.1.2.3 Box Plot



Bagian *Box Plot* menyajikan representasi visual yang difokuskan pada analisis sebaran data numerik secara lebih terperinci, khususnya untuk mengidentifikasi keberadaan nilai ekstrim atau pencilan (*outliers*). Melalui grafik ini, rentang pemusatan distribusi data yang mencakup nilai minimum, kuartil, garis tengah (median), hingga nilai maksimum dapat dipetakan dengan jelas dan ringkas. Penggunaan visualisasi *box plot* ini sangat penting dalam tahap evaluasi kualitas dataset, karena membantu pembaca maupun analis dalam mendeteksi anomali atau variasi data yang menyimpang terlalu jauh dari kelompok mayoritas.

5.1.3 Analisis Klinis

5.1.3.1 Heatmap Korelasi



Bagian *Heatmap* Korelasi menyajikan visualisasi matriks yang secara spesifik memetakan tingkat hubungan linier antar variabel klinis terhadap status target pasien. Pemetaan grafik ini menunjukkan bahwa tingkat glukosa darah (*blood_glucose_level*) dan kadar HbA1c (*hbA1c_level*) mencatatkan koefisien korelasi tertinggi dengan nilai berturut-turut sebesar 0,42 dan 0,40, menjadikannya sebagai faktor penentu utama yang sejalan dengan standar diagnosis diabetes secara medis. Selanjutnya, metrik kondisi fisik berupa Indeks Massa Tubuh (BMI) sebesar 0,21 serta indikasi penyakit penyerta seperti hipertensi sebesar 0,20 turut memperlihatkan korelasi positif yang signifikan terhadap peningkatan probabilitas risiko secara keseluruhan. Sebagai konklusi analisis, tingginya nilai korelasi yang merata antara variabel *risk_score* terhadap seluruh parameter medis utama, yakni berada pada rentang 0,35 hingga 0,47, secara empiris mengonfirmasi bahwa skema kalkulasi penilaian risiko yang dirancang pada sistem telah tervalidasi dan berfungsi dengan sangat baik.

5.1.3.2 hbA1c_level x Glukosa



Bagian ini menyajikan visualisasi *scatter plot* yang menganalisis hubungan langsung antara kadar HbA1c dan tingkat glukosa darah terhadap status diabetes pasien. Berdasarkan grafik tersebut, terlihat jelas adanya tren korelasi positif, di mana peningkatan tingkat glukosa darah berbanding lurus dengan kenaikan kadar HbA1c. Selain itu, pengelompokan data berdasarkan warna memperlihatkan batas kondisi kesehatan yang sangat tegas; distribusi titik biru yang merepresentasikan pasien non-diabetes terkonsentrasi rapat pada rentang nilai indikator yang rendah, sedangkan titik merah untuk pasien terdiagnosis diabetes mendominasi area kanan atas dengan nilai metrik yang tinggi. Pola sebaran visual ini secara efektif memvalidasi temuan matriks korelasi sebelumnya, menegaskan bahwa kombinasi tingginya kedua parameter laboratorium tersebut merupakan indikator klinis yang paling krusial dan akurat dalam memprediksi status diabetes seorang pasien.

5.1.3.3 Faktor Risiko



Bagian Faktor Risiko menyajikan representasi diagram batang yang secara komparatif membandingkan tingkat prevalensi diabetes berdasarkan berbagai kategori klinis dan gaya hidup pasien. Berdasarkan visualisasi tersebut, terlihat jelas bahwa keberadaan penyakit penyerta atau komorbiditas memberikan dampak kerentanan yang paling ekstrem. Kelompok pasien dengan riwayat penyakit jantung dan hipertensi mencatatkan persentase kejadian diabetes tertinggi yang melonjak jauh melampaui angka rata-rata keseluruhan populasi. Selain itu, faktor kondisi fisik seperti obesitas dan faktor demografis berupa usia lanjut juga secara konsisten menunjukkan tingkat kerentanan yang tinggi, sedangkan kebiasaan merokok memberikan pengaruh peningkatan risiko yang lebih moderat. Pemetaan analitis ini secara logis menyimpulkan bahwa riwayat medis bawaan dan kondisi fisik merupakan katalis utama yang paling krusial dalam memicu probabilitas diabetes, sehingga kelompok pasien ini memerlukan prioritas penanganan dan pemantauan klinis yang lebih ketat.

5.1.3.4 Tren Usia



Bagian Tren Usia menyajikan analisis visual berupa grafik garis ganda yang menggambarkan perkembangan kasus diabetes di berbagai rentang kehidupan pasien. Grafik pada bagian atas menunjukkan pola peningkatan jumlah diagnosis yang berbanding lurus dengan pertambahan umur, di mana titik puncak kerentanan tertinggi secara konsisten terakumulasi pada kelompok lanjut usia. Sebagai pelengkap, grafik pada bagian bawah memperlihatkan proporsi distribusi usia populasi secara keseluruhan guna memastikan bahwa lonjakan kasus tersebut dievaluasi dengan konteks demografis yang akurat. Secara analitis, pergerakan tren ini menegaskan secara logis bahwa penuaan merupakan faktor risiko alami yang sangat mempengaruhi kemunculan diabetes, sehingga fokus pencegahan serta pemantauan klinis mutlak diprioritaskan bagi pasien yang telah memasuki fase usia lanjut.


5.1.4 SQL ↔ NoSQL Integration



Halaman SQL ↔ NoSQL Integration pada dashboard dirancang untuk menggambarkan alur integrasi data antara PostgreSQL sebagai penyimpan data klinis terstruktur dan MongoDB sebagai penyimpan data gaya hidup berbasis dokumen dalam arsitektur pipeline tiga lapisan. Pada layer PostgreSQL, hasil agregasi menunjukkan peningkatan prevalensi diabetes yang konsisten seiring naiknya risk score, mulai dari 0% pada skor 0 hingga mencapai 71,1% pada skor 6, sehingga memperlihatkan hubungan yang kuat antara tingkat risiko dan kemungkinan diabetes. Sementara itu, analisis pada layer MongoDB menunjukkan bahwa kelompok former smoker memiliki prevalensi diabetes tertinggi dibanding current smoker dan never smoker, yang mengindikasikan adanya dampak jangka panjang dari riwayat merokok terhadap kondisi

metabolik pasien. Pada tahap integrasi lintas sistem, data dari kedua sumber digabungkan berdasarkan `patient_id` dan diperkaya menggunakan kategori risiko multifaktor untuk menghubungkan antara smoking history dan tingkat risiko diabetes. Hasil visualisasi menunjukkan bahwa kelompok CRITICAL dengan status never smoker justru memiliki prevalensi diabetes tertinggi, sehingga menegaskan bahwa faktor klinis seperti hipertensi dan penyakit jantung memiliki pengaruh yang lebih dominan dibanding status merokok.


5.1.5 Apache Spark Results



Pada subbab Spark SQL, dashboard menampilkan empat query agregasi yang masing-masing menelaah hubungan antara variabel klinis dengan prevalensi diabetes dari sudut pandang berbeda. Query 1 memperlihatkan distribusi prevalensi diabetes berdasarkan kategori BMI, di mana hasilnya secara konsisten menunjukkan bahwa semakin tinggi kategori BMI (menuju obesitas), semakin tinggi pula angka prevalensi diabetes pada kelompok tersebut. Query 2 menganalisis kelompok usia dan menemukan bahwa prevalensi diabetes meningkat drastis seiring bertambahnya usia, dengan kelompok usia lanjut mendominasi angka diagnosis. Query 3 menegaskan kembali pola linier antara *risk score* dan prevalensi dari 1,7% pada skor 1 hingga melampaui 70% pada skor 6 yang divisualisasikan sebagai grafik garis naik bertahap. Query 4 melengkapi gambaran ini dengan memetakan distribusi glukosa darah per kategori HbA1c, menunjukkan bahwa pasien pada kategori *diabetic-range* ($HbA1c \geq 6,5\%$) secara konsisten memiliki rata-rata glukosa darah paling tinggi. Secara keseluruhan, keempat

query ini membangun narasi klinis yang koheren: risiko diabetes bersifat multidimensi dan dapat diprediksi melalui kombinasi biomarker BMI, usia, HbA1c, serta skor risiko komposit.

5.1.6 Data Explorer



Halaman Data Explorer dirancang sebagai antarmuka inspeksi dataset secara langsung (*raw data view*) yang sepenuhnya responsif terhadap filter global yang telah diterapkan pengguna melalui sidebar. Bagian atas halaman menampilkan empat metrik ringkas yaitu total baris, total kolom, jumlah *missing values*, dan rentang usia. Metrik tersebut memberikan gambaran cepat tentang kondisi dataset yang sedang aktif. Nilai *missing values* dikodekan secara statis sebagai "0" dalam kode, yang mencerminkan bahwa dataset telah melalui tahap pembersihan data (*data cleaning*) sebelumnya sehingga tidak ada nilai kosong yang tersisa pada dataset yang digunakan. Panel kontrol di sisi kiri memungkinkan pengguna memilih kolom yang ingin ditampilkan melalui *multiselect*, menentukan jumlah baris yang dimuat (10 hingga 200 baris), memilih kolom pengurutan, serta menentukan arah urutan secara *ascending* atau *descending* — seluruh interaksi ini bereaksi secara *real-time* terhadap tabel yang ditampilkan di panel kanan.

Dari sisi logika kode, implementasi tabel menggunakan pendekatan kondisional yang cerdas: apabila kolom *risk_score* atau diabetes termasuk dalam kolom yang dipilih pengguna, tabel akan secara otomatis menerapkan pewarnaan gradien pada kolom tersebut untuk memudahkan identifikasi visual pola risiko, sementara warna teks dipaksa menjadi hitam agar tetap terbaca di atas latar berwarna. Jika tidak ada kolom yang dipilih, sistem menampilkan pesan informatif sebagai *fallback* yang menjaga pengalaman pengguna tetap bersih. Tersedia tombol unduh yang memungkinkan pengguna mengeksport dataset yang

sedang ditampilkan sesuai filter kolom yang aktif dalam format CSV, menjadikan halaman ini bukan sekadar alat eksplorasi visual tetapi juga titik akhir distribusi data (*data export endpoint*) yang praktis bagi pengguna yang memerlukan subset data untuk analisis lanjutan di luar dashboard.

BAB VI

KESIMPULAN

Arsitektur pipeline big data end-to-end yang dibangun menggunakan ekosistem Apache Spark terbukti mampu memproses dataset kesehatan berskala besar (100.000 baris) secara efisien , sekaligus berhasil mengimplementasikan penyimpanan hybrid yang sinkron antara PostgreSQL untuk data klinis terstruktur dan MongoDB untuk data riwayat medis semi-terstruktur. Melalui pendekatan cross-system analytics yang diintegrasikan ke dalam dashboard Streamlit , proyek ini berhasil mengidentifikasi secara kuantitatif bahwa kondisi kronis seperti riwayat penyakit jantung (32,14%), hipertensi (27,90%), dan kadar HbA1c tinggi (24,96%) merupakan faktor risiko terkuat pemicu diabetes , yang dipertegas oleh akurasi segmentasi di mana populasi kategori CRITICAL memiliki prevalensi diabetes tertinggi mencapai 51,6%.